SAM2 视频对象分割对抗攻击
方法讲解文档

VADI v4.1 项目

2026 年 4 月

摘要

本文档面向项目内部讲解，系统说明当前对 SAM2.1-Tiny 视频对象分割模型的对抗攻击方法（VADI v4.1）。讲解顺序为：（1）SAM2 的工作机理；（2）实验中识别出的薄弱环节；（3）针对这些薄弱环节设计的 “插入诱饵帧 + 原始帧稀疏扰动” 联合攻击策略；（4）每一项设计的依据与已有实验证据；（5）当前的实验进度与下一步计划。本方法的目标是在严格保真度约束（首帧 ϵ=2/255、其余帧 ϵ=4/255 且 LPIPS 受限）以及 “无真值监督” 的前提下，最大化整段视频的 J-drop。

目录

1 项目概览与现状 **2**

2 SAM2 工作机理 **2**

2.1 整体架构 2

2.2 Memory Bank 的容量与组织 3

2.3 Cross-Attention 的角色 3

3 SAM2 的薄弱环节 **3**

3.1 薄弱点 A：当前帧 Hiera 通路（已验证） 3

3.2 薄弱点 B：脆弱窗口（vulnerability windows） 4

3.3 薄弱点 C：相邻帧的 “桥接窗口” 4

4 方法设计：插帧 + δ 联合策略 **4**

4.1 威胁模型与保真度约束 4

4.2 步骤 1：脆弱窗口识别（placement） 5

4.3 步骤 2：诱饵帧合成（ν 优化） 5

4.4 步骤 3：桥接 δ（每个插入点附近的稀疏扰动） 5

4.5 步骤 4：Anchored Stage 14（v4.1 hot-fix）的优化目标 5

4.6 步骤 5：Polish/Revert 自适应包装器（部署侧） 6

5 设计依据：为什么这样设计 **6**
5.1 为什么必须保留“插入” 6
5.2 为什么 δ 要“稀疏 + 局部” 6
5.3 为什么需要双层保真度 7
5.4 为什么用 polish/revert，而不是“更强的 joint” 7
5.5 Memory Hijack 框架的来源 7

6 当前实验数据与攻击效果 **7**
6.1 主结果：13 片段 v4.1 联合方法 J-drop 8
6.2 机制证据：A3 因果切除（4/4 STRONG） 8
6.3 决断 10-clip 配置 ablation（决定方法形态） 8
6.4 视觉化产物（5 段 side-by-side MP4） 9
6.5 进度与阻塞 10

7 结语 **10**

1 项目概览与现状

研究目标。在攻击者可访问完整原始视频，但只能在视频处理流水线中“插入合成帧”与“在原始帧上施加 δ 扰动”的威胁模型下，攻击 SAM2.1-Tiny 的提示驱动视频对象分割（VOS）。评估口径为“处理后整段视频”（包含插入帧与 δ 帧），不是裁掉插帧后的 clean-suffix。

当前版本。 VADI v4.1，方法核心由三部分组成（详见第 4 节）：

1. K=3 内部诱饵帧插入（vulnerability-aware top-K 位置）；
2. 在每个插入点附近的少量原始帧上施加桥接 δ；
3. 部署侧的“polish/revert 自适应包装器”。

已有结果。

- 13 个 DAVIS 验证片段上完成 v5 polish 与 Stage 14 v4.1。
- A3 因果切除实验（4 个片段已完成）：4/4 STRONG，证实“插入位置上的 memory hijack”机制存在。
- 关键的反向证据：B2 ablation 否决了原 v2 提出的“memory-bank 中毒”叙事——bank 架构层面并不是关键路径，真正起作用的是“当前帧 Hiera 特征通路”。
- 决断性 10-clip 实验（K3_insert_only_top）平均 J-drop 0.537，是当前最强单一配置。

当前阻塞。 A3 在剩余 9 个片段的扩展受到服务器侧 swap 全满（其他用户作业占用）导致 systemd-oomd 反复杀掉初始化阶段的 python 进程，需等待资源恢复或迁移到 V100。

2 SAM2 工作机理

2.1 整体架构

SAM2 的视频分割流程可以抽象为 “逐帧前向 + 跨帧记忆” 的循环。对一段长度为 T 的视频 $\{I_t\}_{t=0}^{T-1}$：

1. **首帧**（$t = 0$）：用户给出提示（mask 或 box），SAM2 在该帧上做一次完整 prompt-driven 分割，得到首帧 mask $\hat{M}_0$，并把首帧的高维特征写入 memory bank。
2. **后续帧**（$t \geq 1$）：
   (a) Hiera 主干对 I_t 提取多尺度图像特征 F_t；
   (b) Memory Attention 模块以 F_t 作为 query，对 memory bank 中过往帧的 (key, value) 做 cross-attention，得到 “记忆增强” 的特征 $\tilde{F}_t$；
   (c) Mask Decoder 在 $\tilde{F}_t$ 上做一次轻量解码，得到当前帧 mask $\hat{M}_t$；
   (d) 当前帧的特征以 (key, value, temporal_pos_emb) 的形式 *写回 memory bank*，供后续帧使用；FIFO 队列：bank 满则丢弃最旧的非提示帧。

2.2 Memory Bank 的容量与组织

SAM2.1-Tiny 默认 memory bank 容量为 7 帧（1 个 prompt-anchored 槽位 + 6 个 FIFO 槽位）。bank 中每个槽位存储：

- 该帧的 Hiera 投影后特征 $V \in \mathbb{R}^{H' \times W' \times C}$（cross-attention 的 value）；
- 对应的 key（cross-attention 的 key）；
- 时序位置嵌入（temporal positional embedding）；
- 该帧 mask 的 dense embedding。

2.3 Cross-Attention 的角色

在 `memory_attention.layers[-1].cross_attn_image` 这一关键算子中，当前帧的每一个空间 token 与 bank 中所有历史帧的所有空间 token 做注意力，得到一个加权后的 “跨帧记忆读出” 向量。这个读出与当前帧自身特征经残差连接、归一化后，最终送入 mask decoder。

关键观察：当前帧的分割结果不仅取决于自身 Hiera 特征，还取决于它从 memory bank 中 “读到了什么”。这是 SAM2 强于 image-only SAM 的根本，但也是攻击面所在。

3 SAM2 的薄弱环节

通过 v1 → v4 的迭代实验，我们识别出三类可被利用的薄弱环节。每一类都有对应的实验证据支撑（或反证）。

3.1 薄弱点 A：当前帧 Hiera 通路（已验证）

现象。一旦在视频流中插入一个 “扰动可控的合成帧”，该帧的 Hiera 特征会无差别经过 memory attention 与 mask decoder，与原视频内容产生不一致的 “假证据”；这一 “假证据” 会进入 memory bank，并污染后续帧的 cross-attention 读出。

反驳老叙事。 VADI v2 最初的解释是 “毒化 memory bank 槽位”，但 B2 ablation（直接屏蔽 bank 中相应槽位的写入）显示：屏蔽与不屏蔽对最终 J-drop 的影响远小于预期。**结论：**起作用的并不是 “毒化某个 bank 槽位”, 而是 “当前帧 Hiera 通路本身被合成内容所欺骗”。这一发现迫使我们把 v3 的 “pure δ” 路线（无插入）也排除，并最终回到 “插入 + δ” 的联合形式（详见第 4 节）。

支撑实验：

- B2 ablation（2026-04-22）：bank-poisoning 假说被证伪。
- A3 ablation（2026-04-27 起）：4/4 STRONG。该实验直接屏蔽 “插入帧的 memory write”，并对照 “非插入帧的同类屏蔽”；结果表明攻击效应仅在插入位置上才有显著的因果影响，确认插入位置即为攻击发生的物理点。

3.2 薄弱点 B：脆弱窗口（vulnerability windows）

现象。在原视频上 SAM2 自身就有一些 “挣扎时刻”：高速运动、遮挡边界、低对比度、镜头切换处，置信度抖动明显。攻击者拥有原视频访问权，可在攻击前先用 clean-SAM2 跑一遍，识别这些位置，之后把诱饵帧插入到这些位置，攻击效果显著强于固定的 FIFO 周期位置（如 $\{6, 12, 14\}$）。

为何不能盲选 top-K？决断性 10-clip ablation 显示：纯 vulnerability top-K placement 反而输给 random（仅在 2/10 个片段上获胜）。原因是 top-K 容易集中在视频开头几帧，被 SAM2 的 prompt-anchored 帧 “盖过”。**结论：**应使用 top-K 的 “松弛变体”——例如避开前 N 帧后再从 top-K 中挑选，或将 top-K 与 random 混合。

3.3 薄弱点 C：相邻帧的 “桥接窗口”

现象。在插入诱饵帧 t^* 后，紧跟其后的 L 个原始帧仍然要经过 memory attention，并读取已经被诱饵污染的 memory bank。如果在这 L 帧上施加少量 δ 扰动，可以桥接并放大诱饵的效应；但若 δ 加得不当（例如施加到非桥接窗口的远帧），反而是净伤害（10-clip decisive 显示 joint 平均比 insert-only 低 0.156 pp）。

结论：δ 必须空间和时间上都 “聚焦”——只在 $(t^*, t^*+L]$ 的桥接窗口生效，且要受 LPIPS 与 SSIM 双约束。

4 方法设计：插帧 + δ 联合策略

4.1 威胁模型与保真度约束

攻击面：给定原视频 $V = \{I_t\}$ 与首帧提示 P_0，攻击者输出处理后视频

$$\tilde{V} = \mathcal{A}(V, P_0; W) = \mathrm{Insert}(V, \{(t_k^*, D_k)\}_{k=1}^{K}) \oplus \delta,$$

其中 $W = \{t_1^*, \ldots, t_K^*\}$ 是 $K = 3$ 个插入位置，D_k 是第 k 个诱饵帧内容，δ 是叠加在指定原始帧上的逐像素扰动。

保真度约束（双层）：

- 提示帧 f_0：$\|\delta_0\|_\infty \le 2/255$ 且 $\mathrm{SSIM}(I_0, I_0 + \delta_0) \ge 0.98$；
- 其余帧：$\|\delta_t\|_\infty \le 4/255$ 且 $\mathrm{LPIPS}(I_t, I_t + \delta_t) \le F_{\mathrm{lpips}} \approx 0.20$。

评估口径：处理后整段视频上 SAM2 跟踪的 mask 与 clean-SAM2 自身预测之间的 J（IoU）下降量，记为 J-drop。

4.2 步骤 1：脆弱窗口识别（placement）

输入：clean-SAM2 在 V 上的逐帧 mask 与置信度序列。

1. 计算每帧的 "脆弱性得分" s_t：综合置信度方差、相邻帧 IoU 跳变、运动幅度。
2. 候选集 $\mathcal{C} = \{t : s_t \ge \tau\}$。
3. 用 `joint_curriculum` 三段式搜索（prescreen → phase_1 stick-breaking 参数化 → phase_2 trust region → phase_3 suffix probe）从 $\mathcal{C}$ 中选出 $W^* = \{t_1^*, t_2^*, t_3^*\}$，使后续联合优化的 J-drop 上界最大。
4. **鲁棒化：**避免 W^* 全部落在视频前 5 帧（被 prompt-anchored 帧覆盖），必要时混入 random-K。

4.3 步骤 2：诱饵帧合成（ν 优化）

每个插入位置 t_k^* 对应一张 $H \times W \times 3$ 的可学习诱饵图 $D_k = \mathrm{Sigmoid}(\nu_k)$：

- **语义构造：**诱饵内容来自 "oracle-trajectory v4"——结合相邻原始帧做对象 crop + harmonization，再 paste 到诱饵位置；这是真正的对象/背景级合成（非简单平移），用于诱导 SAM2 把诱饵当作 "合理的下一帧"。
- **优化目标：**见 4.5。

4.4 步骤 3：桥接 δ（每个插入点附近的稀疏扰动）

对每个 t_k^* 定义桥接窗口 $\mathcal{B}_k = (t_k^*, t_k^* + L]$（$L$ 由 `post_insert_radius` 控制，默认 2–3 帧）；仅在 $\bigcup_k \mathcal{B}_k$ 上施加 δ_t，其余帧 $\delta_t = 0$。这与 v3 的 "pure δ"（全帧 δ）有本质不同——后者已被实验证伪。

4.5 步骤 4：Anchored Stage 14（v4.1 hot-fix）的优化目标

整段视频上的损失由三项组成：

$$\mathcal{L}_{\text{total}} = \underbrace{\mathcal{L}_{\text{keep margin}}}_{\text{首帧锚定保留}} + \lambda_1 \underbrace{\mathcal{L}_{\text{keep full}}}_{\text{密集保留（v4.1 hot-fix）}} + \lambda_2 \underbrace{\mathcal{L}_{\text{gain suffix}}}_{\text{后缀 J-drop 增益}} . \tag{1}$$

- $\mathcal{L}_{\text{keep margin}}$：在 prompt 帧附近的 γ_{insert} 窗口与 post-insert 后局部 keep 区上保持与 clean-SAM2 一致；
- $\mathcal{L}_{\text{keep full}}$（**v4.1 关键 hot-fix**）：把 keep 区扩展到*整段后缀的密集 keep frame*——这一改动让 dog 片段的 J-drop 从 0.5005 跳到 0.6351，是 v4 失效模式（loss query window 与 δ support window 耦合，导致 ν 失去梯度信号）的根因修复；
- $\mathcal{L}_{\text{gain suffix}}$：仅在攻击希望生效的 J-drop 后缀区上推动 mask 偏离 clean-SAM2。

监督信号：全程使用 clean-SAM2 的伪标签（无真值），并按置信度加权——这是 GT-free 设定下的核心选择。

4.6 步骤 5：Polish/Revert 自适应包装器（部署侧）

由于 v4.1 在不同片段上稳定性差异大，我们在部署阶段引入 “polish accept/revert” 机制：

$$\tilde{V}_{\text{deploy}} = \begin{cases} \tilde{V}_{\text{joint}}, & \text{若J-drop}(\tilde{V}_{\text{joint}}) - \text{J-drop}(\tilde{V}_{\text{insert_only}}) \geq \theta, \\ \tilde{V}_{\text{insert_only}}, & \text{否则}. \end{cases}$$

论文层 claim 改写：从最初的 “joint > only” 改为 “adaptive wrapper ≥ only”——这是面向 AAAI 评审的鲁棒性 claim，既不夸大 joint 的稳定优势，也保留了 “有时 joint 更强” 的事实。10-clip 验收门槛：$\geq 5/10$ wins、平均 $\geq +0.05$、中位数 > 0、top 比例 $< 40\%$。

5 设计依据：为什么这样设计

5.1 为什么必须保留 “插入”

历史教训非常明确：

- v1 仅插入诱饵（无 δ）：效应集中但天花板低；
- v2 插入 + bank-poisoning loss：B2 证伪；
- v3 仅 δ（无插入）：用户拒绝（“纯 δ 不是我们想攻击的接口”），且实验上表明 J-drop 上限明显劣于 insert-only。

因此插入是**方法核心机制**（CLAUDE.md 中固化为硬约束）。任何后续重构都必须保留插入。

5.2 为什么 δ 要 "稀疏 + 局部"

10-clip decisive ablation 给出三条强信号：

1. 全帧 δ（v3）相对于 insert-only 是*净伤害* (-0.156 pp 平均)；
2. insert-only with vulnerability top-K 是当前最强单点（mean 0.537）；
3. 若 δ 仅施加在桥接窗口 $\mathcal{B}_k$ 上，方差降低、平均提升——这是 v4.1 联合方法的 raw J 0.5715 的来源（注：该数值是 6 RAW + 7 A0 fallback 的混合，C2 "joint > only" 尚未充分支持，需要做 paired A0 baseline 实验）。

5.3 为什么需要双层保真度

- 提示帧 f_0 是 "真值锚点"——若提示帧失真过大，SAM2 在第一步就被攻击者操纵，威胁模型变得不真实。因此 $\epsilon = 2/255$ 与 SSIM 双约束。
- 其余帧的 $\epsilon = 4/255$ 与 LPIPS floor 约束保持视觉上 "像真原帧" 的强度，避免靠 "高频噪声" 而非 "合理的对象/背景偏移" 来驱动 J-drop。

5.4 为什么用 polish/revert，而不是 "更强的 joint"

Codex 多轮 review 一致指出：在 10 个片段上 joint 与 insert-only 的优势不稳定。强行宣称 "joint > only" 是高风险 claim，AAAI 评审会要求 paired baseline 全胜（高门槛）。改成 "adaptive wrapper"：

- 头部 claim 是 "包装器 $\geq$ insert-only"（容易满足）；
- 机制 claim 是 "在条件 θ 满足时 joint 严格超过 insert-only"（按片段 case-by-case 报告）。

这种 "两层 claim" 结构是当前 AAAI 风险的最低化设计（mock score 6/10 vs 原叙事 4/10）。

5.5 Memory Hijack 框架的来源

A3 因果切除实验是 C1.a memory hijack claim 的核心证据：

- **条件**：在插入位置 t_k^* 屏蔽 `non_cond_frame_outputs` 的写入；
- **对照**：在非插入位置 w_k（控制集）做相同屏蔽；
- **度量**：$d_{\text{mem}}(t)$ 在 cross-attention 读出向量上的 L2 距离差；以及 J 在桥接窗口 $(w_k, w_k + L]$ 上的塌陷率。

4/4 STRONG（pre-registered tier）说明 "insert 位置上的 memory write 是必要的"，对应论文中 "插入帧通过 cross-attention 因果性地劫持后续帧的 memory 读出" 这一机制 claim。

6 当前实验数据与攻击效果

口径说明（重要）：本节所有 J-drop 指标均在 *v4.1 旧 framing 下生成*（max J-drop attacker-side, $\epsilon = 4/255$, LPIPS≤0.20）。2026-04-28 用户已转向 publisher-side stealth 框架，主指标将切换为 *原始帧 J + Unusable-Track Rate + Sustained Failure Rate*，预算收紧到 LPIPS≤0.03（见 `PIVOT_REVIEW_2026-04-28.md`）。旧数据仍能反映方法的攻击容量（capacity），但不是 publisher-side claim 的最终主表。

6.1 主结果：13 片段 v4.1 联合方法 J-drop

完成 polish 的 13 个 DAVIS 片段中，6 个已完成 RAW joint Stage 14 v4.1 联合优化并导出指标，其余 7 个 partial-C 批次缺 metadata（仅 frames 在）。下表给出已完成 6 片段的逐片段攻击效果，配置为 `K3_top_R8_b-dup_l-dc_o-ad_d-post_s-fs__ot`（K=3 插入 + bridge δ + oracle-trajectory v4 + post-insert radius L=2）。

Clip	T_{proc}	W^*（插入位置）	J_{baseline}	J_{attacked}	ΔJ	攻击成功
camel	93	[2, 14, 30]	0.984	0.025	**0.959**	完全塌陷
bear	85	[9, 12, 42]	0.969	0.131	**0.838**	强
breakdance	87	[6, 12, 42]	0.981	0.239	**0.743**	强
dance-twirl	93	[10, 26, 50]	0.980	0.260	**0.721**	强
dog	63	[1, 23, 37]	0.978	0.343	**0.635**	中
libby	52	[1, 11, 17]	0.963	0.382	**0.581**	中
Mean (n=6)	—	—	**0.976**	**0.230**	**0.746**	—

表 1: 6 个 RAW joint 完成的片段的攻击效果（旧 framing）。J_{baseline} 为 clean-SAM2 在原视频上的 J 自一致，J_{attacked} 为 v4.1 处理后整段视频上的 J，$\Delta J = J_{\text{baseline}} - J_{\text{attacked}}$。所有 6 片段 $\Delta J \geq 0.58$，4 / 6 达到 ≥ 0.7，camel 几乎完全塌陷（J_{attacked}=0.025）。

解读：

- Mean $\Delta J = 0.746$（n=6）——在严格保真度（ϵ=4/255, LPIPS≤0.20）下，攻击在每一片段都*至少把 J 砍掉一半*。
- Mean RAW J 0.5715（hybrid 6 RAW + 7 A0 fallback，codex 引述的全 13 片段数）远低于这 6 片段的 mean 0.746，因为 7 个 NA 片段以 A0 polish 替代（J-drop 较低）。
- 用户 publisher-side 转向后，目标缩窄为 $\Delta J \in [0.25, 0.35]$ **+ LPIPS ≤ 0.03 + 人工 stealth ≥ 85%**，当前 0.746 远超阈值，表明*容量充足，但需要交易掉一部分到 stealth*。

6.2 机制证据：A3 因果切除（4/4 STRONG）

A3 在 4 个片段上完成（dev-4 / partial-B 批次）。逐片段屏蔽 *insert 位置的* memory write 后，整段 J 显著恢复，验证插入位置即为攻击的因果点；而屏蔽非 *insert 控制位置的*相同操作几乎无效（diff 列）。

Clip	J_{baseline}	$J^{\text{block}}_{\text{attacked}}$	$J^{\text{block}}_{\text{control}}$	Δ_{att}	Δ_{ctl}	**Tier**
dog	0.343	0.923	0.343	**+0.580**	+0.000	STRONG
horsejump-high	0.511	0.939	0.510	**+0.429**	−0.001	STRONG
blackswan	0.583	0.880	0.586	**+0.297**	+0.004	STRONG
judo	0.492	0.710	0.494	**+0.218**	+0.002	STRONG
Mean (n=4)	0.482	**0.863**	0.483	**+0.381**	+0.001	**4/4 STRONG**

表 2: A3 因果切除：J_{baseline} 是 v4.1 攻击下、不做任何屏蔽的攻击后 J（攻击成功 → 低 J）。$J^{\text{block}}_{\text{attacked}}$ 屏蔽 insert 位置 memory write 后 J 显著恢复（4 个片段平均提高 +0.381），证明 insert 是机制因果点。$J^{\text{block}}_{\text{control}}$ 屏蔽相同数量的非 insert 位置（matched random），J 几乎不动（mean diff +0.001）。Pre-registered tier 阈值：$\Delta_{\text{att}} \geq 0.20$ 且 $\Delta_{\text{att}} - \Delta_{\text{ctl}} \geq 0.10$ 为 STRONG。

解读：A3 是论文的 **C1.a 主张证据**——“插入帧通过 cross-attention 因果性地劫持后续帧的 memory 读出”。4/4 STRONG（每个片段都通过预登记阈值，且控制组几乎不动）是非常强的因果信号。剩余 9 个片段被服务器资源阻塞，待 swap 释放后补全。

6.3 决断 10-clip 配置 ablation（决定方法形态）

2026-04-24 在 10 个 held-out 片段上对 4 个候选配置做配对比较，决定 v4.1 的最终形态：

配置	平均 ΔJ	相对 insert-only	解读
K3_insert_only_top	**0.537**	—	单一最强：仅插入 + top-K 脆弱性放置
K3_joint_top	0.381	−0.156 pp	全帧 δ 是净伤害
K3_insert_only_random	0.460	−0.077 pp	random 平均略低，但 8/10 片段胜 top
K3_joint_random	0.412	−0.125 pp	仍劣于 insert-only

表 3: 10-clip decisive ablation（旧 framing）。两条强信号：（i）全帧 δ 是净伤害——这迫使我们把 δ 限制到 bridge 窗口 $\mathcal{B}_k$；（ii）random vs top-K placement 在 8/10 片段上 random 胜出（top-K placement inversion 问题）。结论：δ 必须稀疏 + 局部，placement 需要 top-K 的鲁棒性变体（避开前 N 帧或与 random 混合）。

6.4 视觉化产物（5 段 side-by-side MP4）

为肉眼检查攻击效果，在 `viz/` 下生成了 5 段对比视频（上半 clean DAVIS / 下半 attacked，6 fps）：

用户观察到的失效模式（触发 publisher-side 转向）：oracle-trajectory v4 在 insert 帧上保留了原始位置的对象残影 + 新位置的 paste 对象，呈现双对象鬼影。视觉上明显合成。这是 publisher-side 叙事下的致命问题——即使 ΔJ 大，被 reviewer 直接判 “high fidelity” 措辞失效。codex 推荐替换为 *interpolation-based interstitial*（RIFE / FILM / IFRNet），见 `PIVOT_REVIEW_2026-04-28.md`。

Clip	文件	ΔJ	视觉特征
camel	`camel_clean_vs_attacked.mp4`	0.959	完全塌陷，bridge δ 几乎不可见
bear	`bear_clean_vs_attacked.mp4`	0.838	攻击稳定，诱饵中可见双对象残影
breakdance	`breakdance_clean_vs_attacked.mp4`	0.743	强攻击，mid-clip 恢复后再次塌陷
dance-twirl	`dance-twirl_clean_vs_attacked.mp4`	0.721	长 clip，3 次 insert 互相加强
dog	`dog_clean_vs_attacked.mp4`	0.635	早 insert (t^*=1) 导致 prompt 后立即偏轨

表 4: 已生成的视觉化对比视频。插入帧用红框 + "INSERTED DECOY FRAME" 标记。

阶段	状态	产物
M0 smoke（real-SAM2 1 clip）	完成	parity OK + blocked-frame OK
M3 polish（13 clips）	完成	`vadi_runs/v5_paper_all_merged/`
RAW joint Stage 14 v4.1（6 / 13 clips）	完成	mean $\Delta J = 0.746$
A3 mechanism gating（4 / 13 clips）	完成	4/4 STRONG
A3 mechanism gating（剩余 9 clips）	**阻塞**	systemd-oomd 杀进程（YaoXiaoxu `pt_data_worker` 占 swap 4 GB
RAW joint 剩余 7 片段（partial-C）	阻塞	同上
publisher-side pivot 实施	待开始	interpolation 诱饵 + LPIPS≤0.03 + 重新评估

表 5: 2026-04-28 时刻的实验进度。

6.5 进度与阻塞

现存问题与下一步

1. **服务器资源阻塞**：Pro 6000 swap 100% 满（uid 1072 `2023D_YaoXiaoxu` 占 4 GB；uid 1057 `2025D_ShiGuangze` 占 1.8 GB）。systemd-oomd `ManagedOOMMemoryPressure=kill@50%PSI` 在 SAM2 import 阶段就 kill 进程。`systemd-run --user --scope` opt-out 与 per-clip 子进程拆分均无效（per-clip 有概率成功，blackswan 通过、bear/bmx-trees 被杀）。需等待 Yao 训练结束或迁移 V100。

2. **publisher-side 转向最高杠杆实验**（codex F2）：4-6 片段 interpolation-based interstitial frame 试点 + bridge δ on L=2 at ϵ=2/255，eval 用 *原始帧 GT J only* + 人工 ghosting 检查。此实验决定整个 pivot 是否可行。

3. **C2 主张的不充分**：当前 hybrid mean 0.5715 (6 RAW + 7 A0 fallback) 不能支撑 "joint > insert-only"；需要 paired A0 baseline（同 13 片段，仅 polish 不做 joint search）。

4. **新发现的 prior art 风险**：Liu et al. "Protecting Your Video Content" (CVPR 2025) 已破坏 "first publisher-side video cloak" 主张。新可声称 firstness 缩窄为 "first publisher-side cloaking method for prompt-driven VOS / SAM2-style extraction"。

5. **Claim 矩阵切换**（旧 → 新 framing）：

   (a) 旧（attacker-side）：mean $\Delta J \geq 0.55$（已达 0.746 in 6 / 13）；

   (b) 新（publisher-side）：原始帧 $\Delta J \in [0.25, 0.35]$ + LPIPS ≤ 0.03 + Unusable-Track Rate

（$J < 0.5$ 帧比例）+ Sustained Failure Rate（连续 5 帧 $J < 0.3$ 比例）+ 人工 stealth $\geq 85\%$。

7 结语

VADI v4.1 的核心思想是：*利用攻击者对原视频的完整访问权识别 SAM2 自身的脆弱时刻，在那些时刻插入语义合理的诱饵帧（劫持 cross-attention 读出），并在紧邻的桥接窗口上施加少量 δ 来延展、放大诱饵的效应。*

设计上严守三条硬约束（CLAUDE.md）：

- “插入 + δ 联合” 是方法的不变核心（Method Design Constraints）；
- 论文方向必须保持正向 decoy 攻击叙事，禁止 audit/falsification pivot（Paper Direction Constraint）；
- 任何方法实现都必须先经 Codex review 再上 GPU（Code Review Protocol）。

下一步的关键实验是 paired A0 baseline，它将决定 C2 主张能否进入论文头版。